第八讲 正则表达式

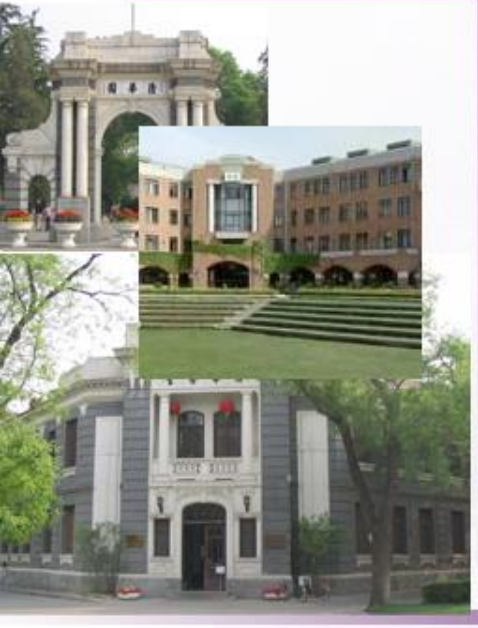

清华大学计算机系

正则表达式

- 什么是正则表达式？
- 正则表达式有什么用？
- 如何用正则表达式？
- 很多语言都支持正则表达式

什么是正则表达式

- 在计算机科学中，指一个用来描述或者匹配一系列符合某个句法规则的字符串的**单个字符串**
  - ✓**010-\d{8}**
  - ✓**010-627[789]\d{4}**
- 鼻祖
  - ✓美国新泽西州的**Warren McCulloch**
  - ✓美国底特律的**Walter Pitts**
- 推广人
  - ✓**Ken Thompson Unix**创始人
  - ✓**Jeffrey Friedl**

正则表达式用途

- 模式匹配：是否满足某一特征的字符串
  - ✓匹配电话号码
  - ✓匹配URL
- 查找字符串
- 字符串替换

传统的字符串匹配

- 普通字符
  - ✓字母、数字、汉字、下划线
  - ✓没有被定义特殊意义的标点符号
- 如果每个字符都是普通字符，就是传统字符串匹配

- 如何进行复杂匹配？
  - ✓匹配北京电话号码
  - ✓匹配**Email**地址

通用正则表达式

与“多种字符”匹配的表达式

表达式	作用
\d	任意一个数字，0~9 中的任意一个
\w	任意一个字母或数字或下划线，也就是 A~Z,a~z,0~9,_ 中任意一个
\s	包括空格、制表符、换页符等空白字符的其中任意一个
.	小数点可以匹配除了换行符（\n）以外的任意一个字符
\D	非\d
\W	非\w
\S	非\s

例子

- 北京电话号码
  - ✓010-\d\d\d\d\d\d\d\d
- 用户名长度为的6的Gmail地址
  - ✓\w\w\w\w\w\w@gmail.com

匹配长度为100的？

匹配次数的符号

表达式	作用
{n}	表达式重复n次，比如："\w{2}" 相当于 "\w\w"；"a{5}" 相当于 "aaaaa"
{m,n}	表达式至少重复m次，最多重复n次，比如："ba{1,3}"可以匹配 "ba"或"baa"或"baaa"
{m,}	表达式至少重复m次，比如："\w\d{2,}"可以匹配 "a12","_456","M12344"...
?	匹配表达式0次或者1次，相当于 {0,1}，比如："a[cd]?"可以匹配 "a","ac","ad"
+	表达式至少出现1次，相当于 {1,}，比如："a+b"可以匹配 "ab","aab","aaab"...
*	表达式不出现或出现任意次，相当于 {0,}，比如：“a*b"可以匹配 "b", “aaaab"...

例子

- ✓. 匹配单个字符
  - r.t
  - 匹配 rat rut
  - 不匹配root
- ✓* 匹配0或多个字符
  - r.*t
  - 匹配 rt rot root
- ✓+ 匹配1或多个字符
  - 9+ 匹配9999
- ✓? 匹配0个或1个字符
  - 9? 匹配9

匹配任意字符

表达式	作用
[ab5@]	匹配 **"a"** 或 **"b"** 或 **"5"** 或 **"@"**
[^abc]	匹配 **"a","b","c"** 之外的任意一个字符
[f-k]	匹配 **"f"~"k"** 之间的任意一个字母
[^A-F0-3]	匹配 **"A"~"F","0"~"3"** 之外的任意一个字符

例子

- [ ] 匹配括号中的任何一个字符
  - ✓r[aou]t
  - ✓匹配 rat、rot、rut
  - ✓不匹配 root
- [0-9] 匹配任何数字
- [a-z] 匹配a-z之间的任何字符
- [^a-z] 匹配除了a-z之间的字符
- {i}匹配指定数目的字符
  - ✓A[0-9]{3} 匹配 A123、A348

转义字符

- 转义字符 \
  - ✓\\ 表示\
  - ✓* 表示*
  - ✓\$ 表示 $
  - ✓\. 表示.

贪婪与懒惰

- 贪婪匹配方式
  - ✓最长匹配
- 表达式**a.*b**
- 字符串**aabab**
- 匹配结果 **aabab**

- 怎么得到结果 **aab** 和 **ab?**

贪婪与懒惰

***? 重复任意次，但尽可能少重复**

+? 重复1次或更多次，但尽可能少重复

?? 重复0次或1次，但尽可能少重复

{n,m}? 重复n到m次，但尽可能少重复

{n,}? 重复n次以上，但尽可能少重复

表达式a.*?b
字符串aabab
懒惰匹配结果 aab 和 ab

字符边界

表达式 **de\w**

字符串 **abcdef**

匹配结果 **def**

如何匹配单词？

表达式	作用
^	与字符串开始的地方匹配，不匹配任何字符
$	与字符串结束的地方匹配，不匹配任何字符
\b	匹配一个单词边界，也就是单词和空格之间的位置，不匹配任何字符

例子

- ✓$
  - are you$
  - 匹配 how are you
  - 不匹配how old are you?
- ✓^
  - ^how are
  - 匹配 how are you
  - 不匹配how old are you
- ✓\b
  - \bho\b
  - 匹配 ho are you
  - 不匹配how old are you

逻辑、分组

- **\B 和\b相反**
  - ✓ **\Bthe\B**
  - ✓ **不匹配in the world**
  - ✓ **匹配otherwise**
- **| 或运算**
  - ✓ **0\d{2}-\d{8}|0\d{3}-\d{7}**
- **( )**
  - ✓ **整体被修饰，以后使用分组**
  - ☐ **(\d{1,3}\.){3}\d{1,3} \\ ip地址**
  - ☐ **((2[0-4]\d|25[0-5]|[01]?\d\d?)\.){3}(2[0-4]\d|25[0-5]|[01]?\d\d?)**

分组

- 表达式 (((ab*)c)d)e
- 字符串 abcdef

- 分组结果
  - ✓group(0) = abcde 整个匹配结果
  - ✓group(1) = abcd 第一组结果
  - ✓group(2) = abc
  - ✓group(3) = ab

分组

- **CS**
- 如何匹配出 http://cs.tsinghua.edu.cn
- **<a\s*href\s*=\s*"([^"]*)"\s*title="([^"]*)"[^>]*>**
- **group(1)**
  - ✓ http://cs.tsinghua.edu.cn
- **group(2)**
  - ✓ cs

注释

- (?#comment)来包含注释

- 2[0-4]\d(?#200-249)|25[0-5](?#250-255)|[01]?\d\d?(?#0-199)

例子

- “￥(\d+.?\d*)” 匹配 "$10.9,￥20.5“
- ^[A-Za-z]+$ 匹配由26个英文字母组成的字符串
- ^[A-Z]+$ 匹配由26个英文字母的大写组成的字符串
- ^[a-z]+$ 匹配由26个英文字母的小写组成的字符串
- ^[A-Za-z0-9]+$ 匹配由数字和26个英文字母组成的字符串
- ^\w+$ 匹配由数字、26个英文字母或者下划线组成的字符串

例子

```
^[1-9]\d*$          //匹配正整数
^-[1-9]\d*$         //匹配负整数
^-?[1-9]\d*$        //匹配整数
^[1-9]\d*|0$        //匹配非负整数（正整数 + 0）
^-[1-9]\d*|0$       //匹配非正整数（负整数 + 0）
^[1-9]\d*\.\d*|0\.\d*[1-9]\d*$          //匹配正浮点数
^-([1-9]\d*\.\d*|0\.\d*[1-9]\d*)$       //匹配负浮点数
^-?([1-9]\d*\.\d*|0\.\d*[1-9]\d*|0?\.0+|0)$     //匹配浮点数
^[1-9]\d*\.\d*|0\.\d*[1-9]\d*|0?\.0+|0$         //匹配非负浮点数（正浮点数 + 0）
^(-([1-9]\d*\.\d*|0\.\d*[1-9]\d*))|0?\.0+|0$    //匹配非正浮点数（负浮点数 + 0）
```

例子

- 匹配国内电话号码：**\d{3}-\d{8}|\d{4}-\d{7}**
- 匹配身份证：**\d{15}|\d{18}**
- 匹配ip地址：**\d+\.\d+\.\d+\.\d+**
- 匹配**Email**地址的正则表达式：
  - ✓ **\w+([-+.]\w+)*@\w+([-.]\w+)*\.\w+([-.]\w+)***
- 匹配网址**URL**的正则表达式：
  - ✓ **https?://[^\s]***
- 匹配帐号是否合法(字母开头，允许**5-16**字符，允许字母数字下划线)：
  - ✓ **^[a-zA-Z][a-zA-Z0-9_]{4,15}$**

Python的正则表达式

Python使用正则表达式

- 包re支持正则表示式
  - ✓字符串匹配
  - ✓字符串分解
  - ✓字符串替换

从开头找到第一个匹配match

- **re.match:字符串匹配**
- **re.match的函数原型为：re.match(pattern, string, flags)**
  - ✓第一个参数是正则表达式
  - ✓第二个参数表示要匹配的字符串；
  - ✓第三个参数是标致位，用于控制正则表达式的匹配方式，如：是否区分大小写，多行匹配等等。
- **re.match只匹配字符串的开始，如果字符串开始不符合正则表达式，则匹配失败，函数返回None；如果匹配成功，则返回一个Match**

flags

- re.I 表示大小写忽略
- re.M 多行模式 使 ^ $ 匹配除了string开始结束外，还匹配一行的开始和结束
- re.S “.“ 匹配包括‘\n’在内的任意字符，否则 . 不包括‘\n’
- re.X 为了写正则表达式，会忽略一些空格和#后面的注释
- re.L 本地化　\w也匹配本地化语言 例如汉字

例子

```
import re
text = "JGood is a handsome boy, he is
   cool, clever, and so on..."
m = re.match("(\w+)\s", text)
if m:
    print m.group(), '\n'
else:
    print 'not match'
>>> JGood
```

re.M

```
import re
print re.match("^\d+$", "123\n 234\n")
```

None

```
print re.match("^\d+$", "123\n 234\n",
re.M).group()
```

['123']

找到一个结果search

- re.search和re.match参数相同
  - ✓re.search函数会在字符串内查找模式匹配,直到找到第一个匹配然后返回，如果字符串没有匹配，则返回None。
  - ✓re.match与re.search的区别：re.match只匹配字符串的开始，如果字符串开始不符合正则表达式，则匹配失败，函数返回None；
  - ✓而re.search匹配整个字符串，直到找到一个匹配。

如何得到返回结果

- **rst = re.match()**
- **rst = re.search()**

- **找到的起始位置 rst.start()**
- **找到的结束位置rst.end()**
- **找到的区间 rst.span ()**
- **找到的组 rst.group ()**

例子

```
import re
text = "JGood is a handsome boy, he is cool, clever, and
    so on..."
m = re.search("\s(\w+)\s", text)
if m:
    print m.group(1), m.start(), m.end(), m.span(),'\n'
else:
    print 'not match'
m = re.match("\s(\w+)\s", text)
print m
```

- is 5 9 (5, 9)
- None

找到所有结果

- **re.findall**
  - ✓**re.findall可以获取字符串中所有匹配的字符串，返回一个列表**
  - ✓如：**re.findall('\w*oo\w*', text)；获取字符串中，包含'oo'的所有单词。**
- **re.finditer**
  - ✓**re.finditer可以获取字符串中所有匹配的字符串，返回一个迭代器**
  - ✓如：**re.finditer(‘\w*oo\w*’, text)；返回一个迭代器。**

例子

```
import re
s= '12 drummers drumming, 11 pipers
   piping, 10 lords a-leaping‘
l = re.findall ('\s+\d+', s)
print l
```

[' 11', ' 10']

例子

```
import re
s= '12 drummers drumming, 11 pipers
   piping, 10 lords a-leaping‘
iter = re.finditer('\s+\d+', s)
for i in iter:
    print i.group(), i.span()
```

```
11 (21, 24)
10 (39, 42)
```

re.M

```
import re
print re.findall("\s\d+$", "I love 123\n Do you love 234\n")
[' 234']
print re.findall("\s\d+$", "I love 123\n Do you love 234\n", re.M)
[' 123', ' 234']
```

分组

- 匹配感兴趣的部分并将其分成几个小组
- m = re.match('(a(b)c)d', 'abcd')
  m.group(0)
  'abcd'
- m.group(1)
  'abc'
- m.group(2)
  'b'

命名分组

- m = re.search(r'(?P<word>a.*?b)(ab)', 'aabab')
- m.group('word')
  - aab
- m.group(1)
  - aab
- m.group(2)
  - ab

贪婪 vs 不贪婪

- s = '<html><head><title>Title</title>'
- print re.match('<.*>', s).span()
  - ✓(0, 32)
- print re.match('<.*>', s).group()
  <html><head><title>Title</title>

- print re.match('<.*?>', s).span()
  - ✓(0,6)
- print re.match('<.*?>', s).group()
  <html>

编译为对象compile

- **re.compile**
  - ✓把正则表达式编译成一个正则表达式对象。
  - ✓**compile(pattern, [flags])**
    - 根据正则表达式字符串 **pattern** 和可选的**flags** 生成正则表达式 对象，其中**flags**有下面的定义：
      - **I** 表示大小写忽略
      - **M** 多行模式 使 **^ $** 匹配除了**string**开始结束外，还匹配一行的开始和结束
      - **S** 单行模式 “.“ 匹配包括 ‘\n’在内的任意字符，否则 . 不包括 ‘\n’

```
p = re.compile( '(blue|white|red)')
p.search(“I like blue and red”)
```

Compile 用法

- reobj = re.compile(regex)
- match =reobj.search(subject)
- match =reobj.match(subject)
- result = reobj.findall(subject)
- iter = reobj.finditer(subject)

例子

```
import re
p = re.compile('\s+\d+')
s=p.search('12 drummers drumming, 11 pipers
    piping, 10 lords a-leaping')
print s.group()
```

11

```
m=p.match('12 drummers drumming, 11 pipers
    piping, 10 lords a-leaping')
print m
```

none

例子

```
import re
p = re.compile('\s+\d+')
print p.findall('12 drummers drumming, 11 pipers piping,
    10 lords a-leaping')
     [' 11', ' 10']
s= '12 drummers drumming, 11 pipers piping, 10 lords a-
    leaping‘
p = re.compile('\s+\d+')
iter = p.finditer(s)
for i in iter:
    print i.group(), i.span()
 11 (21, 24)  10 (39, 42)
```

替换 sub

- **re.sub**
  - ✓ **re.sub用于替换字符串中的匹配项。**
  - ✓ **re.sub的函数原型为：**

    re.sub(replacement, string, [count = 0])

    - ✓ 第1个参数是替换后的字符串；
    - ✓ 第2个参数是替换的字符串；
    - ✓ 第3个参数是替换个数。默认为0，表示每个匹配项都替换。

例子

```
p = re.compile( '(blue|white|red)')

print p.sub( 'color', 'blue socks and red
    shoes')
```

color socks and color shoes

```
print p.sub( 'color', 'blue socks and red
    shoes', count=1)
```

color socks and red shoes

切分字符串split

- re.split
  - ✓用来分割字符串
  - ✓split(string , [maxsplit = 0])
  - ✓p = re.compile('\s')
  - ✓print p.split('This is a test, short and sweet, of split().')
    - ☐['This', 'is', 'a', 'test,', 'short', 'and', 'sweet,', 'of', 'split().']
  - ✓print p.split('This is a test, short and sweet, of split().', 3)
    - ☐['This', 'is', 'a', 'test, short and sweet, of split().']

Thanks
Questions?